PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Documentação da entrega

Projeto Variação do preço dos combustíveis nos postos brasileiros

Curso e turma Sistemas de Informação • 6º GCL1 (Noite) • 2026/2

Professor ou professora Marina De Lara

Equipe Eduardo Pereira, Patrick de Oliveira, Roberto Zhou, Matheus Fraiz de Camargo Antonello

Repositório https://github.com/EduardoPereirabsi/PJBL01-Precos-combustiveis

Entrega Curitiba • 21/10/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

O mesmo combustível, no mesmo dia, custa valores diferentes de um posto para outro, inclusive dentro da mesma cidade. O preço final depende de vários fatores, como o imposto estadual (ICMS), o custo de transporte, a bandeira do posto e a concorrência local.

O problema afeta diretamente o consumidor, que paga mais ou menos dependendo de onde abastece, e também quem acompanha o mercado de combustíveis. Entender quais fatores estão associados a essa variação ajuda a explicar por que o preço muda tanto entre postos, cidades e estados.

Objetivo e recorte

Objetivo: preparar uma base confiável dos preços de combustíveis praticados nos postos brasileiros para investigar, nas próximas etapas, quais fatores estão associados à variação de preço.

Período: janeiro/2023 a agosto/2026 (43 meses; abril/2026 não foi publicado pela ANP). **Unidade de análise:** o preço de um produto, em um posto, em uma data. **Abrangência:** postos pesquisados pela ANP nas 27 UFs (471 municípios, 21.645 postos) e 7 produtos.

Limites: a pesquisa da ANP é feita por amostragem, então as conclusões valem para os postos pesquisados, e não para todos os postos do país. Neste RA as perguntas são apenas formuladas.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Qual é a diferença de preço entre regiões e estados para o mesmo produto?	regiao, uf, produto, valor_venda • todo o período
P2	Postos sem bandeira (bandeira branca) cobram preços diferentes dos postos com bandeira?	bandeira, produto, valor_venda, uf • GLP analisado à parte
P3	Quanto o preço varia entre postos de uma mesma cidade?	uf + municipio, cnpj, produto, data_coleta, valor_venda
P4	Em quais estados o etanol compensa mais que a gasolina (regra dos 70%)?	uf, produto (etanol e gasolina), valor_venda por mês
P5	Como os preços evoluíram de 2023 a 2026?	data_coleta (mês), produto, valor_venda • lacuna em abril/2026

Viabilidade inicial

Cada registro traz o produto, o preço, a data, o posto (CNPJ), a localização (região, UF e município) e a bandeira. Com isso é possível comparar preços entre estados e cidades, entre postos com e sem bandeira e acompanhar a evolução no tempo, sempre dentro do mesmo produto.

Lacunas: a coluna Valor de Compra está totalmente vazia, então não é possível estudar a margem do posto; não há dado de imposto, então o efeito do ICMS só pode ser discutido de forma indireta, comparando estados; abril/2026 não existe na origem; e a cobertura varia entre estados e meses (no Amapá, em janeiro/2026, foram só 2 coletas de gasolina).

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação F1 • Levantamento de Preços de Combustíveis, Série Histórica (ANP)

Origem e acesso Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP) • https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis • acesso em 23/09/2026 e 14/10/2026

Formato e volume CSV separado por ponto e vírgula, um arquivo por mês e grupo de produtos (129 arquivos, 633 MB) • 3.717.753 registros • 16 atributos

Cobertura Janeiro/2023 a agosto/2026, sem abril/2026 • 27 UFs, 471 municípios, 21.645 postos e 7 produtos

Condições de uso Dados abertos publicados pela ANP no portal gov.br; acesso público, sem cadastro ou senha

Relação com o problema

É a única fonte do projeto e apoia as cinco perguntas, porque cada registro liga um preço a um produto, um posto, uma data, uma localização e uma bandeira. A P4 usa só etanol e gasolina; a P2 precisa separar o GLP, em que a bandeira tem outro significado (seção 03).

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Lista das 129 URLs: de 2023 a 2025 o nome dos arquivos segue um padrão e é gerado em um laço; em 2026 a ANP mudou o padrão (e publicou um nome com erro de digitação, “cados-abertos-preco”), então os nomes foram copiados da página. Download com requests e cabeçalhos de navegador (User-Agent e Referer), porque o site responde 403 sem eles. Arquivos já baixados não são baixados de novo.	Notebook PJBL_precos_combustiveis.ipynb, seção 2: células “Lista dos arquivos mensais da ANP” e “Download para data/raw/”
2	pd.read_csv com sep=";", encoding="utf-8-sig", dtype="string[pyarrow]", keep_default_na=False e na_values=[""]. Tudo é lido como texto: converter tipos é uma decisão da limpeza. Os 129 arquivos são unidos com pd.concat, com a coluna arquivo_origem.	Seção 2: célula “Leitura e junção dos 129 arquivos”
3	Conferência do cabeçalho de cada arquivo, contagem de linhas por arquivo e por ano/grupo e registro de qual arquivo veio de qual URL.	Seção 2 (saída “Arquivos com cabeçalho diferente: 0”) e data/controle_ingestao.csv

Resultado da ingestão

Foram carregados **3.717.753 registros × 17 colunas** (as 16 da ANP mais arquivo_origem). Os arquivos brutos ficam em data/raw/ (633 MB), fora do Git, porque o próprio notebook baixa tudo de novo da ANP.

Única etapa manual: copiar da página da ANP os nomes dos arquivos de 2026. Abril/2026 não foi publicado (conferido em 23/09 e 14/10/2026).

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação Uma linha representa o preço de venda de um produto, em um posto, em uma data de coleta.

Identificação dos registros Chave natural: CNPJ da Revenda + Produto + Data da Coleta • na origem a chave não é única: 16 linhas duplicadas e 8 linhas com dois preços para a mesma chave (tratadas na seção 04)

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
Regiao - Sigla	Região do país	Texto	N, NE, CO, SE, S
Estado - Sigla	Unidade da federação	Texto	27 UFs
Municipio	Município do posto	Texto em maiúsculas, sem acento	471 municípios
Revenda	Razão social do posto	Texto	1.598 postos com mais de um nome
CNPJ da Revenda	CNPJ do posto	Texto “00.000.000/0000-00” com espaço no início	21.645 postos
Nome da Rua	Endereço: rua	Texto	Livre
Numero Rua	Endereço: número	Texto	Inclui “S/N”, “SN”, “S/Nº”
Complemento	Endereço: complemento	Texto	77% vazio
Bairro	Endereço: bairro	Texto	Livre
Cep	Endereço: CEP	Texto “00000-000”	100% no formato
Produto	Combustível pesquisado	Texto	GASOLINA, GASOLINA ADITIVADA, ETANOL, DIESEL, DIESEL S10, GNV, GLP
Data da Coleta	Data em que o preço foi coletado	Texto dd/mm/aaaa	01/01/2023 a 31/08/2026
Valor de Venda	Preço cobrado do consumidor	Texto com vírgula decimal	R$ na unidade de medida do produto
Valor de Compra	Preço pago pelo posto à distribuidora	Número, sem nenhum valor	100% vazio

Atributo	Significado	Tipo e formato	Unidade ou domínio
Unidade de Medida	Unidade em que o preço está expresso	Texto	R$ / litro, R$ / m³ (GNV), R$ / 13 kg (GLP)
Bandeira	Distribuidora do posto (BRANCA = sem bandeira)	Texto	72 nomes; no GLP, marca do botijão

Diagnóstico de qualidade

ID	Verificação e regra	Resultado observado	Evidência
Q1	Cabeçalho • os 129 arquivos têm as mesmas colunas	0 arquivos diferentes	Notebook, seção 2
Q2	Ausentes • quantidade por coluna	Valor de Compra 100% vazia; Complemento 77%; demais colunas com exatamente 2.713 ausentes	Seção 3
Q3	Linhas • as 16 colunas vazias	2.713 linhas, no fim de diesel-gnv e glp de jan/2023 (“;;;;;;;;”)	Seção 4.1
Q4	Duplicatas • linhas idênticas nas 16 colunas	16 linhas excedentes (sem contar as vazias)	Seção 4.1
Q5	Chave • CNPJ + produto + data com mais de um preço	8 linhas (um posto de Taubaté, jun/2024)	Seção 4.1
Q6	Valor de Venda • tipo e conversão para número	Texto com vírgula decimal; 0 valores que não viram número; 0 menores ou iguais a zero	Seção 4.1
Q7	Valor de Venda • unidade de medida	3 unidades na mesma coluna, uma por produto; a média geral sem separar (R$ 22,23) não tem sentido	Seções 3 e 4.1
Q8	Data da Coleta • formato dd/mm/aaaa	0 fora do formato e 0 fora do mês do arquivo; sem informar o formato, “02/06/2025” vira fevereiro	Seção 4.1
Q9	CNPJ • formato	Todos com espaço no início e pontuação; 100% com 14 dígitos	Seção 4.1
Q10	Bandeira • mesma empresa com nomes diferentes	VIBRA ENERGIA/VIBRA, ALESAT/ALE, SUPERGASBRAS/SUPERGASBRAS ENERGIA	Seção 4.1
Q11	Bandeira • posto-dia com mais de uma bandeira	22.376 casos; 0 sem o GLP (no GLP a bandeira é a marca do botijão)	Seção 4.1
Q12	Posto em mais de um município	33 postos; 0 em mais de uma UF	Seção 4.1

ID	Verificação e regra	Resultado observado	Evidência
Q13	Aditivada mais barata que a comum (mesmo posto e dia)	105 de 608.980 pares (63 em jan–fev/2023)	Seção 4.1
Q14	Outliers • preço fora de 3 × IQR, por produto	28.391 preços (0,76%)	Seção 4.1
Q15	Município com o mesmo nome em mais de uma UF	VALENCA (RJ e BA)	Seção 4.1
Q16	Sem problema: CEP fora do formato, UF em mais de uma região, mês sem as 27 UFs, posto que muda de UF, “NA”/“NULL” no lugar de vazio	0 casos em todas	Seção 4.1

Impacto dos problemas identificados

Os problemas mais graves são os que **mudam o resultado sem dar erro**: misturar as três unidades de medida em uma média, ler a data sem informar o formato (troca dia e mês) e contar a mesma distribuidora com nomes diferentes como empresas distintas. Também é prioridade lembrar que, no GLP, a bandeira não é a do posto.

Linhas vazias, duplicadas e com preço conflitante somam só 0,07% da base, mas precisam sair para que a chave posto + produto + dia seja única. Já os outliers, a aditivada mais barata e os postos em dois municípios não podem ser corrigidos sem outra fonte e, em boa parte, são variação real de mercado.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 • Remover linhas vazias, duplicadas e com preço conflitante • relacionado a Q3, Q4 e Q5

Problema e abrangência

Todas as colunas. 2.713 linhas totalmente vazias (fim de diesel-gnv e glp de jan/2023), 16 linhas idênticas a outra e 8 linhas de um posto de Taubaté com dois preços para o mesmo produto e dia (jun/2024).

Tratamento e justificativa

As linhas vazias foram removidas porque não têm nenhuma informação. Das duplicatas, mantivemos uma ocorrência, porque são linhas completamente iguais. As 8 linhas com preço conflitante foram removidas: não há como saber qual preço foi praticado, e são 8 em 3,7 milhões. Perda total: 2.737 linhas (0,07%).

Implementação Notebook, seção 4.3: Tratamentos 1 a 3 (isna().all(axis=1), drop_duplicates e duplicated(keep=False) na chave)

Validação após o tratamento

Depois do tratamento: 0 linhas vazias, 0 duplicatas e 0 chaves repetidas; de 3.717.753 para 3.715.016 linhas. Regras 3, 4 e 12 da validação final: OK.

Decisão e diagnóstico D2 • Converter preço e data, com formato explícito • relacionado a Q6 e Q8

Problema e abrangência

Colunas Valor de Venda (texto com vírgula decimal) e Data da Coleta (texto dd/mm/aaaa), em todas as linhas.

Tratamento e justificativa

O preço foi convertido para número trocando a vírgula por ponto, porque os cálculos exigem tipo numérico. A data foi convertida com format="%d/%m/%Y", porque sem o formato o pandas pode trocar dia e mês sem avisar. Não usamos errors="coerce": se algum valor fugisse do formato, o notebook pararia em vez de criar vazios.

Implementação Seção 4.3: Tratamentos 7 e 8 (pd.to_numeric e pd.to_datetime)

Validação após o tratamento

0 preços que não viraram número. Regras 5 (preço numérico e maior que zero) e 6 (data do tipo data, entre 01/01/2023 e 31/08/2026): OK.

Decisão e diagnóstico D3 • Unificar os nomes de bandeira • relacionado a Q10

Problema e abrangência

Coluna Bandeira. A mesma empresa aparece com nomes que se sucedem no tempo: VIBRA ENERGIA e VIBRA, ALESAT e ALE, SUPERGASBRAS e SUPERGASBRAS ENERGIA.

Tratamento e justificativa

Substituímos pelo nome mais recente, para que a comparação por bandeira (P2) não divida a mesma empresa em duas. Nenhum registro é perdido: só o texto muda.

Implementação Seção 4.3: Tratamento 9 (replace com o dicionário NOMES_BANDEIRA)

Validação após o tratamento

146.258 linhas alteradas; de 72 para 69 bandeiras distintas. Regra 9 (nenhuma bandeira com nome antigo): OK.

Decisão e diagnóstico D4 • Padronizar o CNPJ, remover colunas e renomear • relacionado a Q2 e Q9

Problema e abrangência

CNPJ da Revenda com espaço inicial e pontuação em todas as linhas; Valor de Compra 100% vazia; colunas de endereço e nome do posto que não são usadas nas perguntas; nomes de coluna com espaço e hífen.

Tratamento e justificativa

O CNPJ ficou só com os 14 dígitos, porque identifica o posto e precisa de uma forma única. Removemos Valor de Compra (nenhum valor no período), Revenda, Nome da Rua, Numero Rua, Complemento, Bairro e arquivo_origem; o CEP foi mantido por estar 100% padronizado. As colunas foram renomeadas em minúsculas e sem espaço, para facilitar o código e a leitura no Spark.

Implementação Seção 4.3: Tratamentos 4, 5 e 6

Validação após o tratamento

De 17 para 10 colunas. Regras 1 (exatamente as 10 colunas planejadas), 2 (nenhum valor ausente) e 7 (CNPJ com 14 dígitos): OK.

Decisão e diagnóstico D5 • Manter as três unidades de medida e a bandeira do GLP • relacionado a Q7 e Q11

Problema e abrangência

Coluna Valor de Venda em R$/litro, R$/m³ (GNV) e R$/13 kg (GLP); coluna Bandeira, que no GLP indica a marca do botijão.

Tratamento e justificativa

Não convertemos as unidades: transformar botijão e m³ em litro exigiria dados que a base não tem. Como cada produto tem uma única unidade, basta comparar preços sempre dentro do mesmo produto. A bandeira do GLP não é erro; foi mantida, com o registro de que análises por bandeira devem separar o GLP.

Implementação Nenhuma alteração nos dados; decisão registrada na seção 4.2

Validação após o tratamento

Regra 8 (cada produto tem uma única unidade de medida): OK. Sem o GLP, nenhum posto-dia tem mais de uma bandeira.

Decisão e diagnóstico D6 • Manter outliers, aditivada mais barata e postos em dois municípios • relacionado a Q12, Q13 e Q14

Problema e abrangência

28.391 preços fora de 3 × IQR (0,76%), 105 pares em que a aditivada custa menos que a comum e 33 postos registrados em dois municípios.

Tratamento e justificativa

Mantivemos. Muitos preços distantes da maioria são variação real de mercado, e removê-los distorceria justamente a dispersão que queremos estudar. Nos outros dois casos não há como saber qual valor está errado sem outra fonte (pode ser promoção ou erro de cadastro); o estado do posto nunca muda.

Implementação Nenhuma alteração nos dados; decisão registrada na seção 4.2

Validação após o tratamento

Os registros continuam na base final. A regra 5 garante que nenhum preço é menor ou igual a zero.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Removidas linhas vazias (2.713), duplicadas (16) e com preço conflitante (8)	−2.737 linhas (0,07%)	Seção 4.3, Tratamentos 1 a 3
D2	Preço convertido para número e data para data, com formato explícito	valor_venda e data_coleta, todas as linhas	Tratamentos 7 e 8
D3	Bandeiras unificadas no nome mais recente	146.258 linhas; 72 → 69 bandeiras	Tratamento 9
D4	CNPJ com 14 dígitos; 7 colunas removidas; nomes em minúsculas	cnpj em todas as linhas; 17 → 10 colunas	Tratamentos 4, 5 e 6
D5	Mantidas as três unidades e a bandeira do GLP	Nenhum registro alterado	Seção 4.2
D6	Mantidos outliers, aditivada mais barata e postos em dois municípios	Nenhum registro alterado	Seção 4.2

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final precos_combustiveis.parquet • data/processed/precos_combustiveis.parquet • Parquet (26,7 MB)

Unidade de observação final Uma linha representa o preço de venda de um produto, em um posto (CNPJ), em uma data; a chave cnpj + produto + data_coleta é única.

Dicionário atualizado 10 colunas: regiao, uf, municipio, cnpj, cep, produto, data_coleta (data), valor_venda (número), unidade_medida e bandeira (texto) • notebook, seção 4.3

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	3.717.753	3.715.016	−2.737 (0,07%): linhas vazias, duplicadas e com preço conflitante (D1)
Atributos	17	10	Valor de Compra, endereço, nome do posto e arquivo_origem removidos (D4)
Células vazias	6.612.186	0	Linhas vazias e colunas vazias removidas (D1 e D4)
Linhas duplicadas (excedentes)	16	0	D1
Linhas com dois preços na mesma chave	8	0	D1
Bandeiras distintas	72	69	Nomes unificados (D3)
Memória ocupada	1.166 MB	531 MB	Tipos corretos e menos colunas (D2 e D4)

Verificações finais

No fim da preparação (seção 4.4 do notebook), **13 regras** conferem o conjunto final, e o notebook para com assert se alguma falhar. Todas passaram:

colunas exatamente as 10 planejadas; nenhum valor ausente; nenhuma linha duplicada; um único preço por posto, produto e dia; preço numérico e maior que zero; data do tipo data, entre 01/01/2023 e 31/08/2026; CNPJ com 14 dígitos; uma única unidade por produto; nenhuma bandeira com nome antigo; só as 27 UFs, cada uma em uma única região; os 43 meses esperados presentes (sem abril/2026); linhas finais = originais − removidas; base original preservada com 3.717.753 linhas.

Evidência: seção 4.4, saída "✓ Todas as regras definidas foram atendidas."

Limitações e pendências

Abril/2026 não existe na origem: as séries mensais terão essa lacuna.

Amostragem e cobertura: a ANP pesquisa uma amostra de postos, e a cobertura varia (no Amapá, as coletas de gasolina caíram de cerca de 90 por mês em 2025 para 2 em janeiro/2026). As conclusões valem para os postos pesquisados.

Cuidados no uso: comparar preços sempre dentro do mesmo produto; separar o GLP nas análises por bandeira; identificar cidades por UF + município (VALENCA existe no RJ e na BA); lembrar que outliers, aditivada mais barata e postos em dois municípios foram mantidos.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/EduardoPereirabsi/PJBL01-Precos-combustiveis • branch main • commit ee1a971

Ambiente Python 3 (Google Colab ou local) • pandas ≥ 2.2, numpy ≥ 1.26, pyarrow ≥ 16, requests ≥ 2.32, matplotlib ≥ 3.8, seaborn ≥ 0.13 • requirements.txt

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	data/raw/, fora do Git: o notebook baixa os 129 CSVs da ANP. O arquivo data/controle_ingestao.csv registra o nome, a URL e as linhas de cada arquivo
Código de ingestão e preparação	PJBL_precos_combustiveis.ipynb, na raiz do repositório (RA1: seções 1 a 5 e 7)
Dados preparados	data/processed/precos_combustiveis.parquet, gerado na seção 4.4
Documentação e dependências	README.md (problema, fonte e como executar) • requirements.txt • este documento

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Abrir o notebook no Google Colab (link no README) ou, localmente, executar pip install -r requirements.txt; rodar a célula de bibliotecas	Saída "✓ Ambiente preparado."
2	Executar a seção 2: lista, download dos 129 arquivos para data/raw/ (cerca de 14 min no Colab) e leitura	"✓ 129 arquivos disponíveis em data/raw/ (633 MB)" e "Shape: 3,717,753 linhas × 17 colunas"
3	Executar as seções 3 e 4 na ordem: exploração, problemas, decisões e tratamentos	"Shape depois: (3715016, 17)" e "Colunas finais (10)"
4	Executar a seção 4.4: validação e gravação da base	"✓ Todas as regras definidas foram atendidas." e data/processed/precos_combustiveis.parquet (26,7 MB)

Verificação da reprodução

14/10/2026 • Eduardo Pereira • Google Colab, aberto a partir do link do GitHub: execução completa do notebook, com download dos 129 arquivos em cerca de 14 minutos, sem erro 403, e as 13 regras de validação OK. O notebook também foi executado do início ao fim em ambiente local (Python 3.12), com os mesmos resultados.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS (ANP). Série histórica de preços de combustíveis e de GLP. 2023–2026. Disponível em: https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-de-precos-de-combustiveis. Acesso em: 14 out. 2026.

PANDAS DEVELOPMENT TEAM. pandas documentation. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 14 out. 2026.

APACHE ARROW. Python (pyarrow) documentation. Disponível em: https://arrow.apache.org/docs/python/. Acesso em: 14 out. 2026.

PUCPR. Data Analytics: Data Ingestion and Data Quality. Material da disciplina (notebook e slides). Curitiba, 2026.

Anexos opcionais

Identificação	Conteúdo	Localização
Anexo A	Controle da ingestão: nome, URL e número de linhas de cada um dos 129 arquivos	data/controle_ingestao.csv
Anexo B	Notebook com todas as saídas: exploração, tabela de decisões, tratamentos e validação	PJBL_precos_combustiveis.ipynb, no repositório

Conferência da entrega

☒ Problema, recorte e perguntas analíticas estão definidos.

☒ Fontes e procedimentos de ingestão estão documentados.

☒ A qualidade foi avaliada com evidências verificáveis.

☒ As decisões de limpeza estão justificadas e validadas.

☒ O conjunto de dados preparado está identificado.

☒ O repositório contém instruções suficientes para reprodução.

☒ Os campos-modelo foram preenchidos e os exemplos revisados.